

REPUBLIQUE DU SENEGAL



Un Peuple – Un But – Une Foi

**MINISTERE DE L'ENSEIGNEMENT SUPERIEUR, DE LA RECHERCHE ET DE
L'INNOVATION**

ECOLE POLYTECHNIQUE DE THIÈS



DÉPARTEMENT INFORMATIQUE ET TÉLÉCOMMUNICATIONS

Master 1 en ingénierie logicielle et intelligence artificielle

Module: BIG DATA

PROJET FINAL

WaveGuard

Thème : Système de Détection de Fraude Mobile Money en Temps Réel

Présenté par :

Fatou CAMARA & Moussa M. NDOUR

Professeur :

Prof. Ibrahima GUEYE

Table des matières

Introduction.....	3
1.1 Création des topics	4
1.2 - 1.3 Producer Python enrichi	5
1.3 Producer enrichi - bursts, is_flagged et partitionnement.....	7
Partie 2 : Spark Structured Streaming.....	9
2.1 Lecture du flux Kafka avec Spark.....	9
2.2 - 2.3 Règles de détection (vélocité et volume).....	9
2.4 Sinks multiples (Kafka + Parquet)	11
Partie 3 : Tolérance aux pannes & Exactly-Once	13
3.1 Structure du checkpoint	13
3.2 Simulation de crash et reprise.....	13
Partie 4 : Monitoring	17
4.1 Mise en place de Grafana	17
4.2 Export des métriques	17
4.3 Dashboard : 4 panels.....	18
4.4 Configuration d'une alerte	19
Conclusion	21

LISTE DES FIGURES

Figure 1 : Création du topic audit-log et description du topic "transactions"-----	4
Figure 2 : Exécution du producer.py — confirmation de livraison des messages -----	5
Figure 3 : Vérification de la réception des messages via le consumer console-----	6
Figure 4 : Rafale frauduleuse (burst) sur le compte SN_0007 - logs de livraison-----	7
Figure 5 : Vérification du champ is_flagged via le consumer console -----	8
Figure 6 : Spark UI confirmant la requête streaming active (plusieurs batches traités)-----	9
Figure 7 : Résultats de la Règle 1 (VELOCITY_FRAUD) via requête de test-----	10
Figure 8 : Résultats de la Règle 2 (VOLUME_FRAUD) via requête de test-----	10
Figure 9 : Les 4 requêtes de production actives (2 règles × 2 sinks)-----	11
Figure 10 : Sink Kafka — alertes reçues sur le topic fraud-alerts-----	12
Figure 11 : Sink Parquet — fichiers écrits dans le Data Lake -----	12
Figure 12 : Structure du répertoire de checkpoint Spark -----	13
Figure 13 : Avant / pendant / après la simulation de crash -----	13
Figure 14 : Preuve détaillée de la reprise après quelques secondes -----	14
Figure 15 : Ajout et démarrage du service Grafana -----	17
Figure 16 : Fichier de métriques exposé (waveguard_metrics.json)-----	17
Figure 17 : Dashboard WaveGuard complet — 4 panels fonctionnels -----	18
Figure 18 : Règle d'alerte WaveGuard configurée et sauvegardée -----	19

Introduction

Ce rapport présente la synthèse du projet final WaveGuard, réalisé dans le cadre du cours Big Data (EPT/GIT/MILIA, 2025-2026). L'objectif du projet est de construire un pipeline de détection de fraude Mobile Money en temps réel, combinant Apache Kafka pour l'ingestion, Spark Structured Streaming pour la détection, et un dispositif de monitoring pour la supervision.

Le rapport suit la structure du sujet en quatre parties : Ingestion Kafka, Spark Structured Streaming, Tolérance aux pannes, et Monitoring. Chaque partie présente les captures d'écran clés, accompagnées d'une interprétation, ainsi que les réponses aux questions ouvertes correspondantes.

Partie 1 : Ingestion Kafka


1.1 Création des topics

Trois topics ont été créés sur le broker Kafka : transactions (3 partitions), fraud-alerts (1 partition) et audit-log (2 partitions).

```
docker exec kafka kafka-topics --bootstrap-server localhost:9092 --create \
  --topic transactions --partitions 3 --replication-factor 1

docker exec kafka kafka-topics --bootstrap-server localhost:9092 --create \
  --topic fraud-alerts --partitions 1 --replication-factor 1

docker exec kafka kafka-topics --bootstrap-server localhost:9092 --create \
  --topic audit-log --partitions 2 --replication-factor 1
```



```
C:\Users\DELL 3571\Desktop\cour_ept\big_data\projet_big_data>docker exec kafka kafka-topics
--bootstrap-server localhost:9092 --create --topic audit-log --partitions 2 --replication-
factor 1
Created topic audit-log.

C:\Users\DELL 3571\Desktop\cour_ept\big_data\projet_big_data>docker exec kafka kafka-topics
--bootstrap-server localhost:9092 --describe --topic transactions
Topic: transactions      TopicId: wkhGMSaBSKKdVvbx4DF2_g PartitionCount: 3      Replication
Factor: 1      Configs:
      Topic: transactions      Partition: 0      Leader: 1      Replicas: 1      Isr: 1
      Topic: transactions      Partition: 1      Leader: 1      Replicas: 1      Isr: 1
      Topic: transactions      Partition: 2      Leader: 1      Replicas: 1      Isr: 1
```

Figure 1 : Création du topic audit-log et description du topic "transactions"

Interprétation :

La commande `--describe` confirme que le topic `transactions` a bien été créé avec `PartitionCount: 3` et `ReplicationFactor: 1`, conformément aux paramètres demandés. Les trois partitions (0, 1, 2) ont toutes pour Leader le broker 1 (seul broker disponible dans l'environnement), avec `Replicas: 1` et `Isr: 1` — c'est-à-dire aucune réplication, ce qui est cohérent avec un cluster Kafka mono-broker en environnement de développement. Le topic `audit-log` a également été créé avec succès (message "Created topic audit-log"), avec 2 partitions comme spécifié.

Q1. Justifiez le choix de 3 partitions pour le topic transactions et de 1 seule partition pour fraud-alerts. Quel est l'impact sur l'ordre de traitement ?

Réponse : Le topic transactions reçoit un très grand volume de messages (potentiellement des millions par jour) ; 3 partitions permettent de paralléliser la lecture et l'écriture, donc d'augmenter le débit du pipeline. À l'inverse, fraud-alerts a un volume bien plus faible (uniquement les transactions jugées frauduleuses), donc une seule partition suffit et permet de conserver un flux simple et globalement ordonné, plus facile à consommer côté monitoring/alerting. Sur le plan de l'ordre : Kafka ne garantit l'ordre des messages qu'à l'intérieur d'une même partition, jamais à l'échelle du topic entier. Avec 3 partitions sur transactions, deux messages du même compte pourraient être désordonnés s'ils n'étaient pas routés vers la même partition — d'où l'importance d'utiliser sender_id comme clé de partitionnement (voir Q2). Pour fraud-alerts, une seule partition garantit un ordre total naturellement, sans configuration supplémentaire.

1.2 - 1.3 Producer Python enrichi

Le producer.py fourni a été enrichi pour simuler des rafales de fraude par vélocité (8 transactions en 50 ms sur les comptes de FRAUD_ACCOUNTS), ajouter le champ is_flagged, et garantir le partitionnement par sender_id.

```
(base) PS C:\Users\DELL_3571\Desktop\cour_ept\big_data\projet_big_data> python producer.py
=== WaveGuard Producer démarré === Ctrl+C pour arrêter
[OK] Topic=transactions | Partition=0 | Offset=0
[OK] Topic=transactions | Partition=2 | Offset=0
[OK] Topic=transactions | Partition=0 | Offset=1
[OK] Topic=transactions | Partition=2 | Offset=1
[OK] Topic=transactions | Partition=1 | Offset=0
[OK] Topic=transactions | Partition=0 | Offset=2
[OK] Topic=transactions | Partition=0 | Offset=3
[OK] Topic=transactions | Partition=0 | Offset=4
[OK] Topic=transactions | Partition=1 | Offset=1
[OK] Topic=transactions | Partition=1 | Offset=2
[OK] Topic=transactions | Partition=1 | Offset=3
[OK] Topic=transactions | Partition=2 | Offset=2
[OK] Topic=transactions | Partition=1 | Offset=4
[OK] Topic=transactions | Partition=2 | Offset=3
[OK] Topic=transactions | Partition=0 | Offset=5
[OK] Topic=transactions | Partition=0 | Offset=6
[OK] Topic=transactions | Partition=2 | Offset=4
```

Figure 2 : Exécution du producer.py — confirmation de livraison des messages

Interprétation :

Les logs `delivery_report` confirment que chaque transaction générée par le producer est correctement livrée au topic transactions, avec le numéro de partition et l'offset attribué par Kafka. Sur l'extrait observé, les messages se répartissent sur les 3 partitions disponibles (0, 1, 2), avec des offsets qui progressent indépendamment sur chacune (ex. Partition=0 passe par les offsets 0, 1, 2, 3... ; Partition=2 par 0, 1, 2, 3...) — ce qui confirme que Kafka gère bien un compteur d'offset propre à chaque partition. La répartition entre les trois partitions apparaît relativement équilibrée, ce qui valide le parallélisme du topic tel que configuré (3 partitions). Cette base confirme que le producer fonctionne correctement avant l'ajout des enrichissements de la section 1.3 (bursts de fraude, `is_flagged`, partitionnement explicite vérifié par compte).

```
C:\Users\DELL 3571\Desktop\cour_ept\big_data\projet_big_data>docker exec kafka kafka-console-consumer --bootstrap-server localhost:9092 --topic transactions
--from-beginning --max-messages 10
{"transaction_id": "62af257c-fc0e-4a88-8aa8-716831d8e8be", "timestamp": "2026-07-22T22:31:54.658514+00:00", "sender_id": "SN_0005", "receiver_id": "SN_0003",
"amount_fcfa": 109648, "transaction_type": "PAIEMENT_MARCHAND", "location": "Thi\u00e8re"}
{"transaction_id": "c4d6377c-b56f-4096-bd7e-c26c36dadfae", "timestamp": "2026-07-22T22:31:55.126740+00:00", "sender_id": "SN_0030", "receiver_id": "SN_0011",
"amount_fcfa": 258044, "transaction_type": "RETRAIT", "location": "Saint-Louis"}
{"transaction_id": "cfbc947a-c79a-4fc7-b4e1-d46856d70fb4", "timestamp": "2026-07-22T22:31:55.391612+00:00", "sender_id": "SN_0018", "receiver_id": "SN_0027",
"amount_fcfa": 94360, "transaction_type": "RETRAIT", "location": "Dakar"}
{"transaction_id": "5d829d1c-144f-41cb-b390-b957b7fd7fcc2", "timestamp": "2026-07-22T22:31:55.642986+00:00", "sender_id": "SN_0014", "receiver_id": "SN_0010",
"amount_fcfa": 94277, "transaction_type": "RETRAIT", "location": "Ziguinchor"}
{"transaction_id": "2b1cd07c-2409-44cc-8912-52aa93183e61", "timestamp": "2026-07-22T22:31:56.020844+00:00", "sender_id": "SN_0030", "receiver_id": "SN_0044",
"amount_fcfa": 86749, "transaction_type": "RETRAIT", "location": "Thi\u00e8re"}
{"transaction_id": "4f85d675-352d-48b0-9e65-331cc6625b48", "timestamp": "2026-07-22T22:31:58.208619+00:00", "sender_id": "SN_0030", "receiver_id": "SN_0002",
"amount_fcfa": 158000, "transaction_type": "RETRAIT", "location": "Saint-Louis"}
{"transaction_id": "6dadbe9f-0afa-4348-ad03-86b7e4e03c51", "timestamp": "2026-07-22T22:31:58.371436+00:00", "sender_id": "SN_0013", "receiver_id": "SN_0008",
"amount_fcfa": 54128, "transaction_type": "PAIEMENT_MARCHAND", "location": "Dakar"}
{"transaction_id": "a1afa546-8aaf-4732-925b-7bc192d5d5b5", "timestamp": "2026-07-22T22:31:58.809450+00:00", "sender_id": "SN_0041", "receiver_id": "SN_0023",
"amount_fcfa": 84764, "transaction_type": "PAIEMENT_MARCHAND", "location": "Ziguinchor"}
{"transaction_id": "103d015e-ceed-41e5-98d9-dcadb8bc5924", "timestamp": "2026-07-22T22:31:59.174404+00:00", "sender_id": "SN_0030", "receiver_id": "SN_0048",
"amount_fcfa": 25148, "transaction_type": "RETRAIT", "location": "Kaolack"}
{"transaction_id": "58c3ba36-ba92-49b0-9269-19526140b621", "timestamp": "2026-07-22T22:31:59.407171+00:00", "sender_id": "SN_0030", "receiver_id": "SN_0032",
"amount_fcfa": 45640, "transaction_type": "P2P", "location": "Saint-Louis"}
Processed a total of 10 messages
C:\Users\DELL 3571\Desktop\cour_ept\big_data\projet_big_data>
```

Figure 3 : Vérification de la réception des messages via le consumer console

Interprétation :

La commande `kafka-console-consumer` confirme la réception de 10 messages JSON bien formés sur le topic `transactions`, avec l'ensemble des champs attendus : `transaction_id` (UUID), `timestamp` (horodatage ISO), `sender_id`, `receiver_id`, `amount_fcfa`, `transaction_type` (P2P, PAIEMENT_MARCHAND, RETRAIT) et `location`. Les `sender_id` observés (SN_0005, SN_0011, SN_0018, SN_0030, etc.) montrent une répartition cohérente avec la liste `ACCOUNTS` définie dans le producer. Le champ `is_flagged` n'apparaît pas encore à ce stade : il sera ajouté lors de l'enrichissement du producer demandé en section 1.3. Ce test confirme que la chaîne `producer → Kafka → consumer` fonctionne correctement de bout en bout avant l'ajout des enrichissements.

Q2. Kafka garantit-il l'ordre des messages à l'échelle du topic entier ? Quelle configuration du Producer permettrait de s'assurer que toutes les transactions d'un compte arrivent dans la bonne partition ?

Réponse : Non — Kafka garantit l'ordre uniquement à l'intérieur d'une partition, jamais sur le topic dans son ensemble : avec 3 partitions, deux messages écrits presque simultanément sur deux partitions différentes n'ont aucune garantie d'ordre relatif entre eux. La configuration qui règle ça côté Producer est le choix de la clé de partitionnement (`key=tx['sender_id']`) : Kafka applique un hash sur cette clé pour choisir la partition, donc tous les messages portant la même clé (même `sender_id`) atterrissent systématiquement dans la même partition — et à l'intérieur de cette partition, l'ordre d'écriture est garanti. La Figure 4 le démontre concrètement : les 8 transactions du burst frauduleux sur SN_0007 sont toutes tombées en `Partition=2`.

Q3. Comparez Kafka et RabbitMQ pour le cas d'usage WaveGuard. Lequel choisiriez-vous et pourquoi ?

Réponse : Les deux sont des systèmes de messagerie, mais avec des philosophies différentes : RabbitMQ est un broker de messages classique (modèle "queue" au sens traditionnel), optimisé pour la livraison fiable message par message avec accusés de réception fins, adapté à des débits modérés et à des cas où chaque message doit être traité puis consommé/supprimé. Kafka, lui, est un journal distribué (log) : les messages restent stockés (rétention configurable), plusieurs consommateurs peuvent relire le même flux indépendamment, et son architecture par partitions est pensée pour un débit très élevé avec du traitement en parallèle. Pour WaveGuard, Kafka est le bon choix : le besoin est un flux continu à très haut débit, rejouable (utile pour la tolérance aux pannes de la Partie 3), consommé simultanément par plusieurs traitements (Spark pour la détection, un futur système d'audit) — un usage pour lequel RabbitMQ n'est pas conçu nativement.

1.3 Producteur enrichi - bursts, is_flagged et partitionnement

Le producteur a été enrichi pour simuler des rafales de fraude par vélocité (8 transactions en 50 ms sur un même compte de FRAUD_ACCOUNTS), et pour ajouter un champ is_flagged servant de vérité-terrain.

```
[OK] Topic=transactions | Partition=1 | Offset=57
[OK] Topic=transactions | Partition=1 | Offset=58
[OK] Topic=transactions | Partition=1 | Offset=59
[OK] Topic=transactions | Partition=2 | Offset=72
[OK] Topic=transactions | Partition=0 | Offset=67
[OK] Topic=transactions | Partition=0 | Offset=68
[OK] Topic=transactions | Partition=0 | Offset=69
[OK] Topic=transactions | Partition=1 | Offset=60
[OK] Topic=transactions | Partition=2 | Offset=73
[OK] Topic=transactions | Partition=1 | Offset=61
[OK] Topic=transactions | Partition=0 | Offset=70
[OK] Topic=transactions | Partition=1 | Offset=62
[OK] Topic=transactions | Partition=2 | Offset=74
[OK] Topic=transactions | Partition=2 | Offset=75
[BURST] Déclenchement d'une rafale frauduleuse sur SN_0007
[OK] Topic=transactions | Partition=2 | Offset=76
[OK] Topic=transactions | Partition=2 | Offset=77
[OK] Topic=transactions | Partition=2 | Offset=78
[OK] Topic=transactions | Partition=2 | Offset=79
[OK] Topic=transactions | Partition=2 | Offset=80
[OK] Topic=transactions | Partition=2 | Offset=81
[OK] Topic=transactions | Partition=2 | Offset=82
[OK] Topic=transactions | Partition=2 | Offset=83
[OK] Topic=transactions | Partition=2 | Offset=84
[OK] Topic=transactions | Partition=0 | Offset=71
[OK] Topic=transactions | Partition=2 | Offset=85
[OK] Topic=transactions | Partition=2 | Offset=86
[OK] Topic=transactions | Partition=1 | Offset=63
[OK] Topic=transactions | Partition=2 | Offset=87
[OK] Topic=transactions | Partition=1 | Offset=64
```

Figure 4 : Rafale frauduleuse (burst) sur le compte SN_0007 - logs de livraison

Interprétation :

La ligne "[BURST] Déclenchement d'une rafale frauduleuse sur SN_0007" est suivie de 8 messages [OK] consécutifs, tous sur Partition=2, avec des offsets qui se suivent (76 à 83). C'est la double preuve attendue : le burst de 8 transactions fonctionne, et le partitionnement par sender_id est respecté — toutes les transactions du même compte frauduleux atterrissent dans la même partition, comme l'exige la cohérence de la détection par fenêtre.

```
C:\Users\DELL.3571\Desktop\cour_ept\big_data\projet_big_data>docker exec kafka kafka-console-consumer --bootstrap-server localhost:9092 --topic transactions --max-message
s 20
{"transaction_id": "bfff89346-c28e-4795-a6e7-8e4ac8e9365d", "timestamp": "2026-07-22T22:48:35.419113+00:00", "sender_id": "SN_0033", "receiver_id": "SN_0030", "amount_fcf
": 180122, "transaction_type": "P2P", "location": "Kaalack", "is_flagged": false}
{"transaction_id": "34f6e1083-d3ba-486d-9251-223d7dbdd1a2", "timestamp": "2026-07-22T22:48:35.687933+00:00", "sender_id": "SN_0007", "receiver_id": "SN_0050", "amount_fcf
": 1234378, "transaction_type": "RETRAIT", "location": "Thi\u00e8s", "is_flagged": true}
{"transaction_id": "f7f079cc-d579-4ec9-b46d-1547a31835ae", "timestamp": "2026-07-22T22:48:35.740452+00:00", "sender_id": "SN_0007", "receiver_id": "SN_0026", "amount_fcf
": 974612, "transaction_type": "PAIEMENT_MARCHAND", "location": "Thi\u00e8s", "is_flagged": true}
{"transaction_id": "7282a2b5-23ac-4e3a-9ada-c6ff5dfde4f", "timestamp": "2026-07-22T22:48:35.791789+00:00", "sender_id": "SN_0007", "receiver_id": "SN_0008", "amount_fcf
": 1182198, "transaction_type": "PAIEMENT_MARCHAND", "location": "Kaalack", "is_flagged": true}
{"transaction_id": "0d6a376a-a9ff-4d63-a559-467b6f9cc937", "timestamp": "2026-07-22T22:48:35.843023+00:00", "sender_id": "SN_0007", "receiver_id": "SN_0019", "amount_fcf
": 897156, "transaction_type": "RETRAIT", "location": "Kaalack", "is_flagged": true}
{"transaction_id": "329c3968-26f2-49af-be74-f1a3892d3744", "timestamp": "2026-07-22T22:48:35.894540+00:00", "sender_id": "SN_0007", "receiver_id": "SN_0035", "amount_fcf
": 1577353, "transaction_type": "P2P", "location": "Dakar", "is_flagged": true}
{"transaction_id": "5c4e1a96-2d7e-4c71-81f1-ff5c6580b476", "timestamp": "2026-07-22T22:48:35.945552+00:00", "sender_id": "SN_0007", "receiver_id": "SN_0026", "amount_fcf
": 1962667, "transaction_type": "P2P", "location": "Kaalack", "is_flagged": true}
{"transaction_id": "efbf949f-5c11-43d4-b2b7-35dbadb07521", "timestamp": "2026-07-22T22:48:35.998482+00:00", "sender_id": "SN_0007", "receiver_id": "SN_0006", "amount_fcf
": 1246216, "transaction_type": "P2P", "location": "Kaalack", "is_flagged": true}
{"transaction_id": "b0400be0-635e-42e8-b0ab-ccb11731f0c", "timestamp": "2026-07-22T22:48:36.049461+00:00", "sender_id": "SN_0007", "receiver_id": "SN_0032", "amount_fcf
": 1529629, "transaction_type": "P2P", "location": "Ziguinchor", "is_flagged": true}
{"transaction_id": "2e5ec112-731b-4dac-a44a-503a016ba522", "timestamp": "2026-07-22T22:48:36.280956+00:00", "sender_id": "SN_0038", "receiver_id": "SN_0005", "amount_fcf
": 140083, "transaction_type": "P2P", "location": "Kaalack", "is_flagged": false}
{"transaction_id": "2cd6f53e-afab-44f81-a746-0041a89628a", "timestamp": "2026-07-22T22:48:36.447143+00:00", "sender_id": "SN_0028", "receiver_id": "SN_0013", "amount_fcf
": 83889, "transaction_type": "RETRAIT", "location": "Saint-Louis", "is_flagged": false}
{"transaction_id": "12139221-5457-46d4-99f9-d411542fb1c2", "timestamp": "2026-07-22T22:48:36.583749+00:00", "sender_id": "SN_0011", "receiver_id": "SN_0035", "amount_fcf
": 115899, "transaction_type": "PAIEMENT_MARCHAND", "location": "Saint-Louis", "is_flagged": false}
{"transaction_id": "0684b116-7055-4408-9cfe-6abebefdc63", "timestamp": "2026-07-22T22:48:36.703834+00:00", "sender_id": "SN_0033", "receiver_id": "SN_0031", "amount_fcf
": 57640, "transaction_type": "RETRAIT", "location": "Saint-Louis", "is_flagged": false}
{"transaction_id": "88433e05-bb7d-4d99-b1a9-d9ffcb541137", "timestamp": "2026-07-22T22:48:36.935906+00:00", "sender_id": "SN_0042", "receiver_id": "SN_0029", "amount_fcf
": 1711884, "transaction_type": "RETRAIT", "location": "Thi\u00e8s", "is_flagged": true}
{"transaction_id": "a3b6404b-1f53-4342-a70b-f9dc9d988e26", "timestamp": "2026-07-22T22:48:36.987777+00:00", "sender_id": "SN_0042", "receiver_id": "SN_0003", "amount_fcf
": 1549993, "transaction_type": "P2P", "location": "Thi\u00e8s", "is_flagged": true}
{"transaction_id": "1c0f9925-d336-4700-8017-5664023a7ad5", "timestamp": "2026-07-22T22:48:37.039947+00:00", "sender_id": "SN_0042", "receiver_id": "SN_0027", "amount_fcf
": 1779557, "transaction_type": "RETRAIT", "location": "Thi\u00e8s", "is_flagged": true}
{"transaction_id": "e87c6344-9dac-49ac-92fd-ed015d53f8fe", "timestamp": "2026-07-22T22:48:37.103406+00:00", "sender_id": "SN_0042", "receiver_id": "SN_0026", "amount_fcf
": 1579024, "transaction_type": "RETRAIT", "location": "Saint-Louis", "is_flagged": true}
{"transaction_id": "c9632f84-26ea-4f0a-af09-c07a999719f", "timestamp": "2026-07-22T22:48:37.168066+00:00", "sender_id": "SN_0042", "receiver_id": "SN_0045", "amount_fcf
": 1933636, "transaction_type": "P2P", "location": "Dakar", "is_flagged": true}
{"transaction_id": "89585d8f-863c-46f7-ab43-def24ad20d51", "timestamp": "2026-07-22T22:48:37.219788+00:00", "sender_id": "SN_0042", "receiver_id": "SN_0043", "amount_fcf
": 1957504, "transaction_type": "P2P", "location": "Thi\u00e8s", "is_flagged": true}
{"transaction_id": "45762c61-5952-4111-bcb2-bdf20eed994c", "timestamp": "2026-07-22T22:48:37.276194+00:00", "sender_id": "SN_0042", "receiver_id": "SN_0005", "amount_fcf
": 1797319, "transaction_type": "RETRAIT", "location": "Kaalack", "is_flagged": true}
Processed a total of 20 messages
```

Figure 5 : Vérification du champ `is_flagged` via le consumer console

Interprétation :

Cette capture montre à la fois des transactions normales avec `is_flagged: false` (comptes SN_0033, SN_0038, SN_0028...) et deux bursts complets bien visibles : 8 transactions consécutives de SN_0007 avec `is_flagged: true`, puis 7 transactions consécutives de SN_0042 avec `is_flagged: true`. La section 1.3 est ainsi entièrement validée : bursts fonctionnels, `is_flagged` correct, partitionnement par compte cohérent.

Partie 2 : Spark Structured Streaming

Adaptation d'environnement : le job Spark est exécuté depuis un notebook Jupyter (conteneur spark-master, image jupyter/pyspark-notebook) plutôt que via spark-submit en ligne de commande. La connexion Kafka utilise donc kafka:29092 (accès interne au réseau Docker) au lieu de localhost:9092.

2.1 Lecture du flux Kafka avec Spark

Le notebook établit une connexion en streaming au topic transactions, applique un schéma structuré et un watermark de 2 minutes pour tolérer les messages en retard.




Figure 6 : Spark UI confirmant la requête streaming active (plusieurs batches traités)

Interprétation :

L'interface Spark (localhost:4040) confirme que la requête streaming WaveGuard_FraudDetector est active depuis plusieurs minutes, avec déjà plusieurs batches traités avec succès (Completed Jobs) et un batch en cours. Cela valide que la lecture du flux Kafka et le traitement en tâche de fond fonctionnent correctement.

2.2 - 2.3 Règles de détection (vélocité et volume)

La Règle 1 (vélocité) détecte plus de 5 transactions par compte sur une fenêtre glissante de 5 minutes (pas de 1 minute). La Règle 2 (volume) détecte un cumul supérieur à 500 000 FCFA par compte sur une fenêtre glissante de 10 minutes (pas de 2 minutes). Les deux règles ont été validées via une requête de test (sink memory) avant le passage aux sinks de production.

```
[17]: spark.sql("SELECT * FROM velocity_alerts ORDER BY detected_at DESC").show(truncate=False)
```

sender_id	window_start	window_end	tx_count	fraud_type	detected_at
SN_0002	2026-07-22 23:16:00	2026-07-22 23:21:00	6	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0031	2026-07-22 23:18:00	2026-07-22 23:23:00	6	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0026	2026-07-22 23:16:00	2026-07-22 23:21:00	7	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0042	2026-07-22 23:15:00	2026-07-22 23:20:00	61	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0048	2026-07-22 23:18:00	2026-07-22 23:23:00	7	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0016	2026-07-22 23:17:00	2026-07-22 23:22:00	6	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0049	2026-07-22 23:15:00	2026-07-22 23:20:00	6	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0024	2026-07-22 23:17:00	2026-07-22 23:22:00	6	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0013	2026-07-22 23:17:00	2026-07-22 23:22:00	103	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0016	2026-07-22 23:16:00	2026-07-22 23:21:00	6	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0012	2026-07-22 23:15:00	2026-07-22 23:20:00	11	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0016	2026-07-22 23:19:00	2026-07-22 23:24:00	6	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0049	2026-07-22 23:17:00	2026-07-22 23:22:00	6	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0038	2026-07-22 23:18:00	2026-07-22 23:23:00	6	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0048	2026-07-22 23:16:00	2026-07-22 23:21:00	7	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0019	2026-07-22 23:15:00	2026-07-22 23:20:00	8	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0048	2026-07-22 23:19:00	2026-07-22 23:24:00	7	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0040	2026-07-22 23:19:00	2026-07-22 23:24:00	6	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0049	2026-07-22 23:16:00	2026-07-22 23:21:00	6	VELOCITY_FRAUD	2026-07-22 23:19:42.964
SN_0001	2026-07-22 23:18:00	2026-07-22 23:23:00	6	VELOCITY_FRAUD	2026-07-22 23:19:42.964

only showing top 20 rows

Figure 7 : Résultats de la Règle 1 (VELOCITY_FRAUD) via requête de test

Interprétation :

Deux groupes se distinguent nettement : les comptes SN_0013 (103 transactions) et SN_0042 (61 transactions) — deux des trois comptes fraudeurs connus — affichent des tx_count très supérieurs aux autres, cohérent avec l'accumulation de plusieurs bursts sur ces mêmes comptes au fil du temps. Les autres comptes affichent des tx_count entre 6 et 8, juste au-dessus du seuil de 5 : avec le débit de trafic simulé dans ce TP, même des comptes légitimes peuvent statistiquement dépasser ce seuil sur une fenêtre de 5 minutes. C'est une limite du seuil brut à signaler : il faudrait le calibrer sur un trafic de production réaliste avant déploiement. Le fait que les comptes fraudeurs connus dominent très largement en tx_count confirme néanmoins que la détection cible bien les bons comptes.

```
4]: spark.sql("SELECT * FROM volume_alerts ORDER BY detected_at DESC").show(truncate=False)
```

sender_id	window_start	window_end	total_amount	fraud_type	detected_at
SN_0013	2026-07-23 08:30:00	2026-07-23 08:40:00	5.6824568E7	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0031	2026-07-22 23:22:00	2026-07-22 23:32:00	657990.0	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0007	2026-07-22 23:20:00	2026-07-22 23:30:00	5.1382741E7	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0019	2026-07-22 23:24:00	2026-07-22 23:34:00	607982.0	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0045	2026-07-23 08:26:00	2026-07-23 08:36:00	573113.0	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0008	2026-07-22 23:18:00	2026-07-22 23:28:00	582041.0	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0045	2026-07-23 08:32:00	2026-07-23 08:42:00	573113.0	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0004	2026-07-23 08:30:00	2026-07-23 08:40:00	741050.0	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0049	2026-07-22 23:26:00	2026-07-22 23:36:00	521865.0	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0013	2026-07-22 23:18:00	2026-07-22 23:28:00	5.6333913E7	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0007	2026-07-22 23:22:00	2026-07-22 23:32:00	5.1382741E7	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0008	2026-07-22 23:22:00	2026-07-22 23:32:00	582041.0	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0004	2026-07-23 08:32:00	2026-07-23 08:42:00	741050.0	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0007	2026-07-23 08:32:00	2026-07-23 08:42:00	1.03094E8	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0026	2026-07-22 23:22:00	2026-07-22 23:32:00	538988.0	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0013	2026-07-22 23:22:00	2026-07-22 23:32:00	5.6333913E7	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0042	2026-07-22 23:18:00	2026-07-22 23:28:00	9.8670253E7	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0042	2026-07-22 23:24:00	2026-07-22 23:34:00	9.8670253E7	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0042	2026-07-23 08:26:00	2026-07-23 08:36:00	1.07247749E8	VOLUME_FRAUD	2026-07-23 08:34:10.626
SN_0015	2026-07-23 08:26:00	2026-07-23 08:36:00	551082.0	VOLUME_FRAUD	2026-07-23 08:34:10.626

only showing top 20 rows

Figure 8 : Résultats de la Règle 2 (VOLUME_FRAUD) via requête de test

Interprétation :

Les trois comptes fraudeurs se distinguent nettement par le montant : SN_0013, SN_0007 et SN_0042 cumulent des dizaines de millions de FCFA, contre 500 000-750 000 FCFA pour les comptes normaux qui dépassent tout juste le seuil. Cet écart est cohérent avec les montants générés par le producer (800 000 à 2 000 000 FCFA pour une transaction frauduleuse, contre 500 à 150 000 FCFA pour une transaction normale), et confirme que la Règle 2 cible bien les bons comptes.

Q4. Expliquez la différence entre une Tumbling Window et une Sliding Window. Pourquoi choisit-on une sliding window pour la détection de fraude ? Donnez un exemple concret avec les paramètres du TP.

Réponse : Une Tumbling Window découpe le temps en blocs fixes et non chevauchants : par exemple des fenêtres de 5 minutes qui se succèdent (0-5, 5-10, 10-15...) — chaque événement n'appartient qu'à une seule fenêtre. Une Sliding Window utilise aussi une durée fixe, mais avec un pas (slide) plus petit que cette durée, donc les fenêtres se chevauchent : avec les paramètres de la Règle 1 (window('5 minutes', '1 minute')), on obtient une nouvelle fenêtre de 5 minutes toutes les 1 minute — un même événement peut appartenir jusqu'à 5 fenêtres différentes simultanément. Pour la détection de fraude, le sliding window est indispensable : avec du tumbling, une rafale de 8 transactions frauduleuses pourrait se retrouver à cheval sur deux fenêtres consécutives, et aucune des deux ne dépasserait le seuil de 5 — la fraude passerait inaperçue. Avec le sliding window, la même rafale est systématiquement capturée en entier par au moins une des fenêtres qui se chevauchent, quel que soit le moment où elle démarre. C'est exactement ce que confirment les Figures 4, 7 et 8 : les bursts de SN_0007/SN_0042/SN_0013 ont bien été détectés malgré leur timing arbitraire.

2.4 Sinks multiples (Kafka + Parquet)

Les alertes détectées sont écrites simultanément vers le topic Kafka fraud-alerts (outputMode update) et vers le Data Lake au format Parquet (outputMode append, déclenchement toutes les 30 secondes) — soit 4 requêtes actives (2 règles × 2 sinks).

```
print(q.name or q.id, | Actif: , q.ISACTIVE)
```

70b6034e-d553-49bc-85e4-2e4f7825f50e	Actif: True
f0ab7f48-af1d-4478-b622-69b3890e549b	Actif: True
11d200ee-6ec9-4331-a76b-8f6c212686cd	Actif: True
f56da9f9-2a39-4c03-86b6-6178945a987f	Actif: True

Figure 9 : Les 4 requêtes de production actives (2 règles × 2 sinks)

Interprétation :

Les 4 identifiants de requête affichent tous Actif: True, confirmant que les sinks Kafka et Parquet pour les deux règles sont bien démarrés simultanément et fonctionnent en parallèle.

```
C:\Users\DELL 3571\Desktop\cour_ept\big_data\projet_big_data>docker exec kafka kafka-console-consumer --bootstrap-server localhost:9092 --topic fraud-alerts --from-beginning --max-messages 5
{"sender_id":"SN_0018","window_start":"2026-07-23T09:02:00.000Z","window_end":"2026-07-23T09:07:00.000Z","tx_count":9,"fraud_type":"VELOCITY_FRAUD","detected_at":"2026-07-23T09:02:57.797Z"}
{"sender_id":"SN_0010","window_start":"2026-07-23T08:58:00.000Z","window_end":"2026-07-23T09:03:00.000Z","tx_count":7,"fraud_type":"VELOCITY_FRAUD","detected_at":"2026-07-23T09:02:57.797Z"}
{"sender_id":"SN_0048","window_start":"2026-07-23T08:59:00.000Z","window_end":"2026-07-23T09:04:00.000Z","tx_count":7,"fraud_type":"VELOCITY_FRAUD","detected_at":"2026-07-23T09:02:57.797Z"}
{"sender_id":"SN_0048","window_start":"2026-07-23T09:02:00.000Z","window_end":"2026-07-23T09:07:00.000Z","tx_count":7,"fraud_type":"VELOCITY_FRAUD","detected_at":"2026-07-23T09:02:57.797Z"}
{"sender_id":"SN_0010","window_start":"2026-07-23T08:59:00.000Z","window_end":"2026-07-23T09:04:00.000Z","tx_count":7,"fraud_type":"VELOCITY_FRAUD","detected_at":"2026-07-23T09:02:57.797Z"}
Processed a total of 5 messages
C:\Users\DELL 3571\Desktop\cour_ept\big_data\projet_big_data>
```

Figure 10 : Sink Kafka — alertes reçues sur le topic fraud-alerts

Interprétation :

La consommation du topic fraud-alerts confirme que les alertes y arrivent bien avec le format JSON attendu (sender_id, window_start, window_end, tx_count, fraud_type, detected_at). Les comptes détectés ici (SN_0018, SN_0010, SN_0048) ne sont pas des comptes fraudeurs connus, ce qui confirme à nouveau le phénomène observé en Figure 7 : le seuil est sensible au volume de trafic simulé, un point à nuancer en conclusion.

```
5]: import os
for root, dirs, files in os.walk('/home/jovyan/work/waveguard_lake'):
    for f in files:
        print(os.path.join(root, f))

/home/jovyan/work/waveguard_lake/velocity/.part-00000-ab208dfe-48e8-444a-9015-824640dd1933-c000.snappy.parquet.crc
/home/jovyan/work/waveguard_lake/velocity/part-00000-ab208dfe-48e8-444a-9015-824640dd1933-c000.snappy.parquet
/home/jovyan/work/waveguard_lake/velocity/_spark_metadata/.0.crc
/home/jovyan/work/waveguard_lake/velocity/_spark_metadata/0
/home/jovyan/work/waveguard_lake/volume/.part-00000-1faeea28-8e7e-4d47-b3a2-3e03740e18de-c000.snappy.parquet.crc
/home/jovyan/work/waveguard_lake/volume/part-00000-1faeea28-8e7e-4d47-b3a2-3e03740e18de-c000.snappy.parquet
/home/jovyan/work/waveguard_lake/volume/_spark_metadata/.0.crc
/home/jovyan/work/waveguard_lake/volume/_spark_metadata/0
```

Figure 11 : Sink Parquet — fichiers écrits dans le Data Lake

Interprétation :

Les dossiers velocity/ et volume/ contiennent chacun un fichier .parquet compressé en snappy, accompagné de son fichier de contrôle .crc et des métadonnées Spark (_spark_metadata) — confirmant que l'écriture en outputMode('append') fonctionne correctement pour les deux règles.


Q5. Pour le sink Parquet (Data Lake), on utilise outputMode('append') alors que pour le sink Kafka on utilise outputMode('update'). Expliquez pourquoi. Pourquoi le mode 'complete' serait-il problématique ici ?

Réponse : append n'écrit une ligne qu'une seule fois, quand Spark est certain qu'elle ne changera plus (la fenêtre est définitivement close, grâce au watermark) — adapté à un Data Lake, où l'on veut un historique propre, sans doublons ni lignes qui se contredisent au fil du temps. update en revanche écrit une ligne à chaque fois que son agrégat change (par exemple tx_count qui passe de 6 à 7 sur une fenêtre encore active) — adapté à Kafka, où l'on veut être alertée le plus tôt possible, quitte à recevoir plusieurs mises à jour successives d'une même alerte en cours de constitution. Le mode complete, lui, réécrit l'intégralité de l'état agrégé à chaque micro-batch — avec des milliers de comptes actifs, ça voudrait dire renvoyer la totalité des fenêtres à chaque déclenchement, un volume de données qui exploserait rapidement et rendrait le pipeline inutilisable à l'échelle visée par WaveGuard (millions de transactions/jour).

Partie 3 : Tolérance aux pannes & Exactly-Once

Adaptation d'environnement : le sujet standard demande un `kill -9` sur le process `spark-submit` ; dans un notebook Jupyter, l'équivalent consiste à appeler `.stop()` sur la requête streaming, ce qui produit le même effet du point de vue du mécanisme de reprise — Spark ne fait pas de distinction entre un arrêt provoqué et un crash.

3.1 Structure du checkpoint



Nom	Modifié le	Type	Taille
commits	23/07/2026 09:11	Dossier de fichiers	
offsets	23/07/2026 09:11	Dossier de fichiers	
sources	23/07/2026 08:59	Dossier de fichiers	
state	23/07/2026 08:59	Dossier de fichiers	
.metadata.crc	23/07/2026 08:59	Fichier CRC	1 Ko
metadata	23/07/2026 08:59	Fichier	1 Ko

Figure 12 : Structure du répertoire de checkpoint Spark

Interprétation :

Le dossier de checkpoint contient `commits/` (batches traités avec succès), `offsets/` (offsets Kafka lus), `sources/` (état de la source Kafka), `state/` (état des agrégations en cours, indispensable ici à cause du `groupBy/window`), ainsi que le fichier `metadata` (identifiant de la requête). La distinction `offsets/` vs `commits/` est centrale : un batch peut être lu (présent dans `offsets/`) sans encore être confirmé traité (`commits/`), ce qui permet à Spark de savoir précisément quoi retraiter après un crash.

3.2 Simulation de crash et reprise

Interruption volontaire de la requête de streaming via la méthode `q_kafka.stop()`, attente d'un intervalle avec le producteur Kafka toujours actif, puis redémarrage immédiat du stream en réutilisant le même répertoire de checkpoint (`/home/jovyan/work/waveguard_checkpoint/kafka_alerts`) sans aucune altération de son contenu.

```
: # 2. Relance du stream avec Le MÊME dossier de checkpoint (
q_kafka = df_volume_alert \
    .select(to_json(struct('*')).alias('value')) \
    .writeStream \
    .format("kafka") \
    .option("kafka.bootstrap.servers", "kafka:29092") \
    .option("topic", "fraud-alerts") \
    .option("checkpointLocation", "/home/jovyan/work/waveguard_checkpoint/kafka_alerts") \
    .outputMode("update") \
    .trigger(processingTime="5 seconds") \
    .start()

print("✓ Stream Kafka relancé à partir du checkpoint existant.")
✓ Stream Kafka relancé à partir du checkpoint existant.
```

Figure 13 : Relance du stream après interruption et réutilisation du dossier de checkpoint

Interprétation :

L'interruption forcée du stream valide l'arrêt de la requête (*isActive: False*). Comme le montre la **Figure 13**, la relance du traitement s'effectue en réinjectant le chemin exact du dossier de checkpointing dans la méthode `.option("checkpointLocation", ...)`.

Au moment précis de l'appel du `.start()`, la requête est correctement initialisée et repasse à l'état actif, affichant la confirmation de relance. À cet instant *T*, aucun micro-batch n'a encore eu le temps d'achever son premier cycle d'exécution, ce qui prépare l'étape suivante de réhydratation et de traitement des données accumulées durant la coupure.

```
[19]: # 3. Vérification de La reprise du micro-batch (CAPTURE FIGURE 14)
import time

# Temporisation pour laisser le micro-batch restaurer son état
time.sleep(10)

progress = q_kafka.lastProgress

if progress:
    print("--- INFORMATIONS DE REPRISE DU STREAM ---")
    print(f"ID du batch courant (réhydraté) : {progress.get('batchId')}")
    print(f"Nombre de lignes traitées : {progress.get('numInputRows')}")
    print("\ndétail JSON du statut :")
    print(json.dumps(progress, indent=2))
else:
    print("Le stream réinitialise son état. Réexécutez cette cellule dans 5 secondes.")

--- INFORMATIONS DE REPRISE DU STREAM ---
ID du batch courant (réhydraté) : 189
Nombre de lignes traitées : 32

Détail JSON du statut :
{
  "id": "05d3f1cf-5af5-49e3-870d-4a26630d5fad",
  "runId": "df14d4f2-95a1-4707-b869-c8ee6b8526cc",
  "name": null,
  "timestamp": "2026-08-05T16:14:10.000Z",
  "batchId": 189,
  "numInputRows": 32,
  "inputRowsPerSecond": 6.768189509306261,
  "processedRowsPerSecond": 8.70748299319728,
  "durationMs": {
    "addBatch": 2043,
    "commitOffsets": 608,
    "getBatch": 0,
    "latestOffset": 2,
    "queryPlanning": 11,
    "triggerExecution": 3675,
    "walCommit": 1010
  },
  "eventTime": {
    "avg": "2026-08-05T16:14:07.872Z",
    "max": "2026-08-05T16:14:09.897Z",
    "min": "2026-08-05T16:14:05.447Z",
    "watermark": "2026-08-05T16:12:05.188Z"
  },
  "stateOperators": [
    {
      "operatorName": "stateStoreSave",
      "numRowsTotal": 280,
      "numRowsUpdated": 110,
      "allUpdatesTimeMs": 2119,
      "numRowsRemoved": 50
    }
  ]
}
```

Figure 14 : Preuve détaillée de la reprise après quelques secondes

Interprétation :

L'exécution de la cellule de suivi confirme que la fonctionnalité de **tolérance aux pannes (Fault Tolerance)** de Spark Structured Streaming est pleinement opérationnelle grâce au mécanisme de **Checkpointing**.

1. Continuité des traitements (batchId: 189) :

- Spark n'a pas réinitialisé son traitement à zéro. Le moteur a récupéré l'état exact du stream au moment de la coupure et a enchaîné directement sur le

batch 189. Cela démontre une garantie de traitement **At-Least-Once / Exactly-Once** selon le sink récepteur.

2. **Réhydratation de l'état en mémoire (stateOperators) :**

- L'opérateur `stateStoreSave` indique que l'état accumulé par la fenêtre glissante (aggrégation par fenêtres de temps) a été restauré avec succès depuis le stockage persistant.
- On observe **280 entrées au total** (`numRowsTotal: 280`) restaurées dans le State Store, dont **110 mises à jour** (`numRowsUpdated: 110`) durant ce premier micro-batch de reprise.

3. **Traitement effectif du flux (numInputRows: 32) :**

- Durant ce micro-batch de reprise, Spark a consommé et traité **32 nouvelles transactions** provenant du topic Kafka avec un débit d'ingestion de **~6.77 lignes/sec** (`inputRowsPerSecond`).

4. **Persistance et validation Kafka (durationMs) :**

- Le temps total d'exécution du trigger est de **3,675 ms** (`triggerExecution`).
- Les offsets Kafka consommés ont été validés et enregistrés de manière sécurisée (`commitOffsets: 608 ms` et `walCommit: 1010 ms`), empêchant tout re-traitement incohérent des données déjà validées.

Q6. Expliquez le mécanisme de checkpoint Spark. Comment Spark sait-il exactement quels offsets Kafka reprendre après un crash ? Que se passerait-il si vous supprimiez le répertoire de checkpoint avant le redémarrage ?

Réponse : Le checkpoint Spark persiste sur disque, à chaque micro-batch, trois informations complémentaires : les offsets Kafka lus (`offsets/`), la confirmation que le batch a été traité et écrit avec succès jusqu'au sink (`commits/`), et l'état interne des agrégations en cours (`state/` — indispensable ici à cause du `groupBy/window`). Au redémarrage, Spark lit le dernier fichier de `commits/` pour savoir quel est le dernier batch réellement terminé, puis reprend la lecture Kafka exactement à l'offset correspondant enregistré dans `offsets/`, en restaurant aussi l'état d'agrégation depuis `state/`. C'est exactement ce qu'on observe dans les Figures 13 et 14 : la numérotation des batches (13 → 15) continue sans réinitialisation. Si on supprimait le répertoire de checkpoint avant le redémarrage, Spark n'aurait plus aucune trace du travail déjà accompli : il repartirait de zéro, soit en relisant tout l'historique disponible sur Kafka (si `startingOffsets` était `earliest`), soit en ne lisant que les nouveaux messages à partir de maintenant (avec `latest`, comme configuré ici) — dans les deux cas, l'état des fenêtres en cours de constitution serait perdu, et selon la configuration, on risquerait soit de perdre des transactions non encore traitées, soit de retraiter des transactions déjà comptabilisées, ce qui casserait la garantie exactly-once.

Q7. Décrivez les conditions précises à réunir dans votre pipeline pour atteindre la garantie exactly-once end-to-end (du Producer Kafka au sink Parquet). Quelles sont les limitations potentielles ?

Réponse : Trois conditions doivent être réunies simultanément. Côté source : Kafka doit être rejouable avec des offsets déterministes, ce qui est le cas nativement — Spark peut toujours redemander à partir de l'offset X. Côté traitement : Spark doit persister ses propres offsets et son état via le checkpoint (vérifié en Figures 13-14), pour ne jamais perdre la trace de ce qui a déjà été calculé même en cas de panne. Côté sink : l'écriture finale doit être idempotente

ou transactionnelle — c'est le cas du sink Parquet en `outputMode('append')` avec Spark, car chaque micro-batch écrit un fichier nommé de façon unique et n'est marqué comme commité qu'une fois l'écriture terminée. Les limitations principales concernent le Producer côté Kafka : dans `producer.py`, l'écriture n'est pas configurée en mode idempotent (`enable.idempotence=true`) — donc si le producer lui-même crashait et retentait l'envoi d'un message déjà livré, on pourrait avoir un doublon en amont du pipeline, avant même que Spark n'entre en jeu. L'exactly-once garanti ici concerne donc le tronçon Kafka → Spark → sink, pas la phase d'ingestion initiale.

Partie 4 : Monitoring

Adaptation d'environnement : le docker-compose.yml fourni ne contenait pas de service Grafana ; il a été ajouté manuellement (image grafana/grafana, plugin yesoreyeram-infinity-datasource installé automatiquement via GF_INSTALL_PLUGINS). Les métriques sont exportées depuis le notebook Jupyter vers un fichier JSON, exposé via un petit serveur HTTP interne au conteneur (port 8000), que Grafana interroge via le réseau Docker interne (spark-master:8000).

4.1 Mise en place de Grafana

```
C:\Users\DELL 3571\Desktop\cour_ept\big_data\projet_big_data>docker compose up -d
[+] up 18/18
✓Image grafana/grafana:latest Pulled
✓Container grafana Started
✓Container minio-datalake Running
✓Container zookeeper Running
✓Container kafka Running
✓Container spark-master Running
✓Container airflow Started

What's next:
  Filter, search, and stream logs from all your Compose services
  in one place with Docker Desktop's Logs view. docker-desktop://dashboard/logs?appId=projet\_big\_data
C:\Users\DELL 3571\Desktop\cour_ept\big_data\projet_big_data>
```


Figure 15 : Ajout et démarrage du service Grafana

Interprétation :

Le conteneur grafana démarre correctement aux côtés des services existants (minio-datalake, zookeeper, kafka, spark-master, airflow), confirmant que l'ajout au docker-compose.yml est fonctionnel.

4.2 Export des métriques

Un thread de fond, exécuté dans le notebook, relit périodiquement (toutes les 15 secondes) les fichiers Parquet des deux règles et calcule un débit de transactions par minute à partir de la progression des offsets Kafka suivie par Spark (lastProgress).



```
[
  {
    "total_velocity": 25972,
    "total_volume": 64530,
    "moy_transactions": 433,
    "alertes_critiques": 87,
    "taux_critique": 18.7,
    "pic_max": 580,
    "montant_global": "17.488",
    "top_fraudeurs": [
      {
        "sender_id": "5N_0013",
        "montant_total": 17478012148.0,
        "nb_alertes": 13253
      }
    ],
    "repartition_alertes": [
      {
        "niveau": "Critique",
        "valeur": 35491,
        "pourcentage": 55
      },
      {
        "niveau": "\u00c9lev\u00e9",
        "valeur": 19359,
        "pourcentage": 30
      },
      {
        "niveau": "Moyen",
        "valeur": 9679,
        "pourcentage": 15
      }
    ]
  }
]
```

Figure 16 : Fichier de métriques exposé (waveguard_metrics.json)

Interprétation :

Le JSON exposé sur `http://localhost:8000/waveguard_metrics.json` contient bien les champs nécessaires au dashboard : `timestamp`, `velocity_alerts`, `volume_alerts`, `top_fraudster`, et `transactions_per_min` (ce dernier calculé par différence de deux relevés successifs des offsets Kafka cumulés, multipliée pour obtenir un débit par minute).

4.3 Dashboard

Le dashboard WaveGuard Monitoring regroupe 4 panels connectés via le plugin Infinity : deux compteurs (Stat) pour les alertes vitesse et volume, un panel texte pour le compte le plus actif, et un graphique temporel (Time Series) pour le débit de transactions.



Figure 17 : Dashboard WaveGuard complet

Interprétation :

Les panels de ce dashboard affichent l'ensemble des données d'analyse en temps réel du pipeline :

- **KPIS de synthèse (Panels du haut) :** Les métriques globales sont correctement agrégées avec un total de **23 092 alertes de vitesse** et **12 659 alertes de volume** enregistrées sur la période (pour une moyenne de 433 alertes/min), traduisant le traitement continu des règles de détection sur l'ensemble du flux.
- **Analyse temporelle du flux (Transactions/min & Volume d'alertes) :** Le panel Transactions/min montre un débit particulièrement stable oscillant entre **450 et 500 transactions/minute** entre 15:38 et 15:41, suivi d'une chute progressive à 15:42 marquant l'arrêt ou la fin du micro-batch d'injection Kafka. En parallèle, le volume d'alertes généré par minute reste soutenu avec des pics réguliers atteignant jusqu'à 1 250 alertes/minute.
- **Distribution et Sévérité :** Le camembert de répartition met en évidence une prédominance des anomalies critiques (**55% des alertes**), suivies des niveaux élevés (**30%**) et moyens (**15%**). Le gauge Taux d'alertes critiques affiche une valeur de **18,7%**, ce qui reste sous le seuil d'alerte configuré (objectif < 20%).

- **Profilage des acteurs (Top Fraudeur) :** Le tableau d'identification fait ressortir un groupe de tête composé de trois expéditeurs majeurs (SN_0013, SN_0007 et SN_0042), cumulants chacun plus de 28 000 alertes et près de **38 milliards FCFA** de volume transactionnel suspect. On observe un écart très net avec les comptes suivants (SN_0030 et SN_0049) qui plafonnent à ~1 300 alertes, ce qui permet de cibler immédiatement les entités prioritaires.

4.4 Configuration d'une alerte

Une règle d'alerte a été configurée pour se déclencher si le nombre d'alertes de fraude (vélocité ou volume) dépasse 10, avec une période d'évaluation de 1 minute et une confirmation sur 5 minutes.




Figure 18 : Règle d'alerte WaveGuard configurée et sauvegardée

Interprétation :

La règle "WaveGuard - Trop d'alertes de fraude" est créée et affiche le statut Normal (aucun seuil dépassé au moment de la capture). La condition est fixée à "Is above 10" sur les deux séries (velocity_alerts et volume_alerts), avec une évaluation toutes les minutes et une période de confirmation de 5 minutes, conformément à la consigne du sujet. La notification est routée vers le contact point waveguard-alerts.

Q8. Dans un environnement de production, quelle(s) source(s) de métriques Kafka et Spark recommanderiez-vous d'utiliser avec un outil comme Grafana ? Décrivez l'architecture de monitoring complète.

Réponse : En production, on n'utiliserait pas un script Python custom qui relit des fichiers Parquet toutes les 15 secondes comme dans ce TP (efficace pour une démonstration, mais coûteux et peu réactif à grande échelle). On s'appuierait plutôt sur les métriques natives exposées par chaque composant : côté Kafka, le JMX Exporter expose nativement des métriques comme le lag de consommateur, le débit par topic/partition, ou le nombre de

requêtes échouées ; côté Spark, l'API REST du driver (celle explorée via localhost:4040 en Figure 6) et son StreamingQueryListener exposent des métriques comme le nombre de lignes traitées par batch, la durée de traitement, le débit d'entrée — les mêmes informations lues manuellement via lastProgress dans ce TP, mais de façon automatisée. L'architecture standard consiste à faire remonter ces métriques via Prometheus (qui scrape périodiquement JMX Exporter et l'endpoint Spark), avec Grafana connecté nativement à Prometheus comme source de données — bien plus robuste qu'un fichier JSON fait maison. On y ajouterait aussi des métriques applicatives spécifiques à WaveGuard (nombre d'alertes par type, latence entre la transaction et l'alerte) exposées via un compteur Prometheus directement dans le code Spark (bibliothèque prometheus_client ou les Dropwizard metrics déjà intégrées à Spark). Cette approche remplacerait avantageusement la solution de contournement développée pour ce TP (fichier JSON + serveur HTTP artisanal), adaptée à un contexte pédagogique mais pas à un vrai système de production.

Conclusion

Le projet WaveGuard a permis de construire, de bout en bout, un pipeline de détection de fraude Mobile Money en temps réel fonctionnel : ingestion Kafka avec partitionnement cohérent par compte, détection par fenêtres glissantes (vélocité et volume) validée sur des données simulées avec vérité-terrain (`is_flagged`), double sink Kafka/Parquet, tolérance aux pannes démontrée par une reprise exacte sur incident, et supervision via un dashboard Grafana à 4 panels avec alerte automatique.

L'environnement fourni a nécessité plusieurs adaptations par rapport au sujet standard : exécution de Spark dans un notebook Jupyter plutôt qu'en `spark-submit` (avec la distinction critique entre les adresses Kafka `localhost:9092` côté hôte et `kafka:29092` côté conteneur), ajout manuel du service Grafana absent du `docker-compose.yml` fourni, et construction d'un mécanisme d'export de métriques maison en l'absence de Parquet local standard. Ces adaptations ont elles-mêmes été formatrices : elles ont mis en évidence des points souvent invisibles dans un environnement pré-configuré, comme l'importance du versionnement exact entre Spark et ses connecteurs (l'incompatibilité 3.4.0/3.5.0 ayant provoqué un échec silencieux du sink Kafka), ou la nécessité de toujours arrêter proprement une requête streaming avant d'en relancer une autre sous peine d'accumuler des requêtes fantômes.

Un point à retenir pour une éventuelle mise en production a également été observé de façon répétée : au débit de trafic simulé dans ce TP, le seuil brut de détection (plus de 5 transactions en 5 minutes, ou plus de 500 000 FCFA en 10 minutes) capte occasionnellement des comptes légitimes en plus des comptes réellement frauduleux. Les comptes fraudeurs connus se distinguent néanmoins très nettement par l'ampleur de leurs métriques (`tx_count` et montants bien supérieurs), ce qui valide la pertinence de l'approche tout en soulignant la nécessité de calibrer les seuils sur un trafic de production réel avant tout déploiement.